Báo cáo hệ thống LLM tư vấn dịch vụ hành chính giai đoạn cơ bản

Bùi Xuân Hoan, Phạm Lê Minh, and Phan Văn Tú

FPT University, Ho Chi Minh City, Vietnam
bhoan2006@gmail.com, minhkek332@gmail.com, vantu12772@gmail.com

Abstract. Báo cáo trình bày quá trình xây dựng một chatbot hành chính cơ bản qua ba giai đoạn. Giai đoạn đầu thiết lập luồng hoạt động giữa giao diện web, Core Backend, AI Service và PostgreSQL bằng phản hồi mô phỏng. Giai đoạn hai bổ sung Retrieval-Augmented Generation (RAG) trên dữ liệu giả lập nhằm kiểm tra truy xuất, tạo bằng chứng và trả lời kèm nguồn. Giai đoạn ba sử dụng 10 thủ tục từ dữ liệu công ty, được chuẩn hóa thành 49 đoạn thông tin, đồng thời thay phản hồi mô phỏng bằng Qwen3-1.7B chạy cục bộ. Kết quả thực nghiệm cho thấy pipeline hoạt động xuyên suốt, output và citation tuân thủ contract, lịch sử hội thoại được lưu và không có lời gọi AI bên ngoài. Hệ thống hiện là nền tảng demo nội bộ, chưa phải sản phẩm production và chưa bảo đảm độ đúng pháp lý cho mọi câu trả lời.

Keywords: Large Language Model · RAG · Qwen · chatbot hành chính · grounded generation

1 Introduction

Các thủ tục hành chính công thường bao gồm nhiều nhóm thông tin như thành phần hồ sơ, thời gian giải quyết, lệ phí và cơ quan tiếp nhận. Người dân có thể gặp khó khăn khi phải tự tìm kiếm và đối chiếu những nội dung này từ nhiều nguồn khác nhau. Vì vậy, một hệ thống sử dụng mô hình ngôn ngữ lớn (Large Language Model – LLM) có thể hỗ trợ người dùng tiếp cận thông tin thuận tiện hơn thông qua hình thức hội thoại tự nhiên.

Mục tiêu dài hạn của dự án là phát triển một trợ lý có khả năng tiếp nhận câu hỏi, xác định thủ tục liên quan, cung cấp câu trả lời dễ hiểu và dẫn nguồn để người dùng kiểm tra lại. Hệ thống có thể hỗ trợ các nhu cầu phổ biến như tra cứu thành phần hồ sơ, thời gian xử lý, lệ phí và nơi tiếp nhận. Tuy nhiên, nó chỉ đóng vai trò hỗ trợ cung cấp thông tin, không thay thế cơ quan hành chính hoặc chuyên gia pháp lý trong các trường hợp cần xác nhận chính thức.

Việc triển khai ngay một hệ thống LLM hoàn chỉnh có nhiều rủi ro. Dữ liệu ban đầu có thể chưa đồng nhất, thiếu trường hoặc chưa được xác minh. Mô hình cũng có khả năng tạo câu trả lời không có căn cứ nếu không được cung cấp nguồn phù hợp. Ngoài ra, hệ thống còn phải giải quyết việc lưu hội thoại, bảo vệ dữ liệu, kết nối các dịch vụ, giới hạn tài nguyên và đánh giá chất lượng. Nếu

phát triển đồng thời tất cả chức năng, nhóm khó xác định lỗi xuất phát từ dữ liệu, truy xuất, model hay phần mềm tích hợp.

Do đó, dự án được triển khai theo hướng tăng dần từ đơn giản đến phức tạp. Giai đoạn đầu xây dựng khung ứng dụng bằng phản hồi mô phỏng. Giai đoạn tiếp theo bổ sung RAG trên dữ liệu giả lập. Sau khi luồng này ổn định, hệ thống sử dụng một phần dữ liệu công ty và Qwen chạy cục bộ. Báo cáo tập trung vào ba giai đoạn trên và đánh giá mức độ hoàn thiện của hệ thống cơ bản.

2 Related Work

RAG kết hợp mô hình sinh với kho tri thức bên ngoài để bằng chứng có thể được cập nhật và kiểm tra. Dự án dùng exact match và BM25 làm baseline truy xuất có chi phí thấp. Qwen3 cung cấp các model gọn nhẹ phù hợp cho thử nghiệm local; phiên bản 1.7B dạng GGUF được chạy qua llama.cpp. Dự án không đề xuất model mới mà tập trung tích hợp pipeline hỏi đáp có nguồn, lưu lịch sử và phản hồi an toàn cho dữ liệu hành chính.

3 Proposed Method

3.1 Tổng quan hệ thống

Hệ thống gồm Frontend, Core Backend, PostgreSQL, mô-đun RAG và AI Service như Hình 1. Người dùng nhập câu hỏi trên giao diện web. Core Backend xác định người dùng, lưu tin nhắn và điều phối quá trình xử lý. RAG tìm các đoạn thông tin phù hợp và đóng gói chúng thành một *Evidence Bundle*. AI Service sử dụng bằng chứng này để tạo câu trả lời. Trước khi trả kết quả, hệ thống kiểm tra cấu trúc, nguồn trích dẫn và áp dụng phản hồi an toàn khi không đủ căn cứ.

Kiến trúc phần mềm được giữ ổn định trong khi thành phần dữ liệu và AI được nâng cấp dần. Giai đoạn 1 dùng Mock AI để kiểm tra luồng ứng dụng. Giai đoạn 2 thêm RAG và Grounded Template trên dữ liệu giả lập. Giai đoạn 3 thay dữ liệu giả bằng một subset dữ liệu công ty và thay template bằng Qwen chạy local.

3.2 Giai đoạn 1 – Khung ứng dụng với Mock AI

Mục tiêu của Giai đoạn 1 là xây dựng một luồng ứng dụng hoàn chỉnh trước khi tích hợp dữ liệu hành chính và LLM thật. Hệ thống gồm giao diện React, Core Backend và AI Service sử dụng FastAPI, PostgreSQL và Docker Compose.

Frontend chuyển câu hỏi tới Core Backend. Backend xác định người dùng, tạo hoặc lấy cuộc hội thoại, lưu câu hỏi và gọi AI Service. Phản hồi mô phỏng được lưu vào PostgreSQL rồi gửi lại giao diện. Giai đoạn này kiểm tra kết nối giữa các dịch vụ, lưu lịch sử sau khi tải lại trang, tách dữ liệu giữa người dùng và tránh tạo tin nhắn trùng lặp. Nhờ đó, lỗi giao diện, API và cơ sở dữ liệu được xử lý trước khi bổ sung RAG.

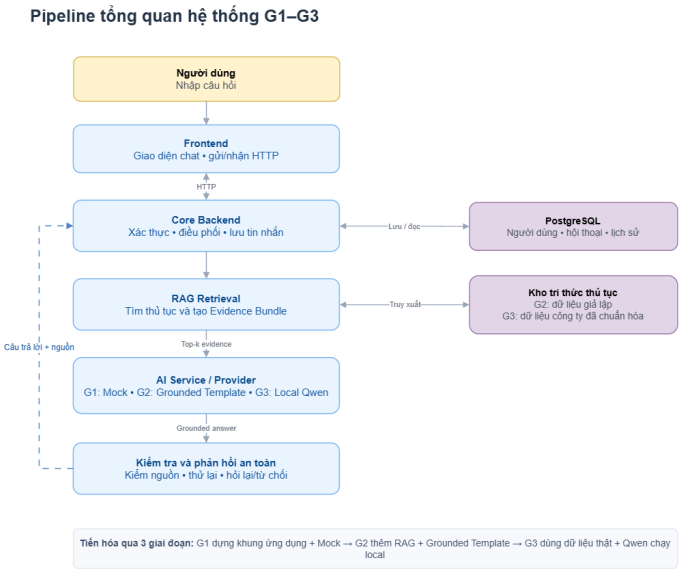


Fig. 1. Pipeline tổng quan của hệ thống qua ba giai đoạn phát triển.

3.3 Giai đoạn 2 – RAG trên dữ liệu giả lập

Giai đoạn 2 xây dựng corpus giả lập gồm 3 thủ tục, 24 fragments và 33 câu hỏi đánh giá. Trong đó, 23 câu thuộc DEV và 10 câu thuộc TEST. Corpus chỉ phục vụ kiểm thử kỹ thuật và không được xem là hướng dẫn hành chính thực tế.

Dữ liệu gồm *Source*, *Procedure*, *Fragment* và *Gold Question*. Trước khi ingest, pipeline kiểm tra schema, phiên bản, mã định danh, quan hệ tham chiếu và mã băm nội dung.

Backend chuẩn hóa câu hỏi rồi kết hợp exact match, tìm từ khóa và BM25. Hệ thống lấy tối đa 5 fragments phù hợp nhất; nếu nhiều thủ tục cùng khớp, hệ thống yêu cầu làm rõ thay vì tự chọn. Các fragments được đóng gói thành *Evidence Bundle*. AI Service sử dụng Grounded Template offline, không dùng Hosted API. Backend chỉ chấp nhận citation thuộc chính bundle của yêu cầu, sau đó bổ sung thông tin nguồn, lưu kết quả và hiển thị trên web. Evidence rỗng hoặc citation sai sẽ dẫn đến hỏi lại hoặc từ chối an toàn.

3.4 Giai đoạn 3 – Dữ liệu công ty và Qwen local

Giai đoạn 3 đưa dữ liệu thực tế và Qwen vào kiến trúc đã được kiểm tra. Workbook do công ty cung cấp chỉ được xử lý local, không đưa lên GitHub và không gửi tới dịch vụ AI bên ngoài.

3.4.1 Tiền xử lý dữ liệu Pipeline dữ liệu gồm các bước chính sau:

1. Đọc workbook, nhận diện tiêu đề, ánh xạ cột và bỏ dòng trống. Pipeline dừng nếu cột có dữ liệu nhưng chưa có quy tắc xử lý.
2. Loại email và metadata không cần thiết; quét số điện thoại, số định danh và chuỗi có dạng API key.
3. Chuẩn hóa khoảng trắng và Unicode theo NFC; tạo ID và mã băm ổn định để kết quả có thể tái tạo.
4. Ánh xạ các trường nghiệp vụ. Phí và thời gian chỉ được parse khi đủ chắc chắn; văn bản gốc được giữ để đối chiếu. Trường thiếu được ghi là `null` hoặc danh sách rỗng, không tự suy đoán.
5. Cách ly bản ghi trùng tên nhưng xung đột; tạo fragments theo từng trường, rồi kiểm tra JSON Schema, tham chiếu, PII, phiên bản và mã băm trước khi phát hành corpus demo.

3.4.2 Corpus và phân chia dữ liệu Nhóm chọn subset gồm 10 thủ tục từ dữ liệu công ty, tạo thành 10 procedure và 49 fragments. Tổng cộng 40 câu hỏi được chia theo thủ tục thay vì chia ngẫu nhiên theo từng câu. DEV gồm 8 thủ tục với 31 câu hỏi; TEST gồm 2 thủ tục với 9 câu hỏi. TEST được khóa bằng mã băm và không dùng để sửa prompt, retrieval hoặc model. Cách chia này hạn chế việc các câu gần giống của cùng một thủ tục xuất hiện ở cả DEV và TEST.

3.4.3 Sinh câu trả lời và kiểm tra an toàn Câu hỏi được định tuyến tới thủ tục phù hợp, sau đó exact match và BM25 chọn tối đa 5 fragments để tạo *Evidence Bundle*. AI Service sử dụng Qwen3-1.7B Q8_0 qua llama.cpp ở chế độ zero-shot, chưa fine-tune. Model chỉ nhận câu hỏi và evidence cần thiết, không nhận toàn bộ workbook hoặc lịch sử người dùng.

Qwen phải trả trạng thái, nội dung và danh sách fragment được trích dẫn theo một output contract. Nếu output sai cấu trúc, hệ thống thử lại tối đa một lần. Nếu vẫn sai nhưng evidence hợp lệ, hệ thống chuyển sang chế độ trích xuất an toàn từ fragment đã duyệt. Câu thiếu tên thủ tục được yêu cầu làm rõ; câu không có bằng chứng nhận trạng thái không đủ dữ liệu. Timeout, mất kết nối hoặc citation ngoài bundle đều được xử lý theo hướng đóng an toàn.

4 Results

4.1 Thiết lập thực nghiệm

Hai thí nghiệm được chạy trên cùng máy local bằng Docker. Thí nghiệm 1 so sánh Grounded Template và Qwen3-1.7B trên cùng 33 câu hỏi giả lập, cùng retrieval và *Evidence Bundle*. Thí nghiệm 2 đánh giá Qwen trên corpus công ty gồm 10 thủ tục và 49 fragments với Top-5 retrieval. Các chỉ số dưới đây đo routing, retrieval, contract, citation và latency; chúng không thay thế đánh giá độ đúng nghiệp vụ của chuyên gia.

Chỉ số	Template	Qwen3-1.7B
Số câu hỏi	33	33
Số lần gọi provider	30	30
Độ chính xác trạng thái	100%	100%
Output hợp lệ	100%	100%
Citation binding hợp lệ	100%	100%
Gold citation recall	60%	90%
Unsafe answer rate	0%	0%
Extractive fallback	0	0
Latency p50 (ms)	2,525	625,485
Latency p95 (ms)	14,425	708,000

Table 1. Kết quả Grounded Template và Qwen trên 33 câu hỏi giả lập.

Chỉ số	DEV	TEST
Số câu hỏi	31	9
Số lần gọi Qwen	31	8
Routing accuracy	100%	100%
Retrieval Recall@5	80%	75%
Độ chính xác trạng thái	96,77%	88,89%
Output hợp lệ	100%	100%
Citation binding hợp lệ	100%	100%
Lỗi HTTP	0	0
Latency p50 (ms)	668,271	666,458
Latency p95 (ms)	1.160,768	1.257,099
Lời gọi AI bên ngoài	0	0

Table 2. Kết quả Qwen trên DEV và TEST của corpus công ty.

4.2 So sánh provider trên dữ liệu giả lập

Table 1 cho thấy cả hai phương pháp đều tuân thủ trạng thái, contract và citation. Template nhanh vì chỉ trích xuất theo quy tắc cố định. Qwen có latency lớn hơn nhưng gold citation recall tăng từ 60% lên 90%, nghĩa là model thường trích dẫn đúng fragment kỳ vọng hơn. Kết quả này không được diễn giải thành độ chính xác pháp lý vì dữ liệu hoàn toàn giả lập và chưa có đánh giá ngữ nghĩa của con người.

4.3 Qwen trên dữ liệu công ty

Trong TEST, một câu được guard xử lý mà không cần gọi model do không đủ điều kiện sinh câu trả lời. Table 2 cho thấy toàn bộ câu hỏi được định tuyến đúng thủ tục; output do Qwen tạo ra đều hợp lệ và citation đều thuộc evidence đã cung cấp. Tuy nhiên, Recall@5 đạt 80% trên DEV và 75% trên TEST, trong khi độ chính xác trạng thái TEST đạt 88,89%. Sai số hiện tại vì vậy tập trung

nhiều hơn ở việc chọn fragment và quyết định trạng thái, thay vì lỗi kết nối hoặc output contract.

5 Future Work

Các giai đoạn tiếp theo sẽ mở rộng từ 10 thủ tục sang corpus đã được phê duyệt và cải thiện liên kết giữa ý định câu hỏi với loại bằng chứng. Dense retrieval và reranker chỉ được bổ sung khi phân tích lỗi chứng minh BM25 chưa đáp ứng. Hệ thống cũng cần hiểu câu hỏi nối tiếp, ghi nhớ thủ tục đang trao đổi và quản lý ngữ cảnh dài hơn. Fine-tune hoặc QLoRA chỉ được xem xét khi có dữ liệu huấn luyện đã duyệt và lỗi diễn giải lặp lại được xác định rõ.

Trước khi triển khai thực tế, cần xây dựng TEST mới có đánh giá nghiệp vụ, đồng thời bổ sung xác thực, phân quyền, giám sát, xử lý đồng thời và quy trình cập nhật dữ liệu. Câu trả lời phải hiển thị phiên bản nguồn, thời điểm hiệu lực và cảnh báo rằng hệ thống không thay thế cơ quan có thẩm quyền.

6 Conclusion

Dự án đã phát triển từ khung ứng dụng dùng Mock AI, sang RAG trên dữ liệu giả lập, rồi tới hệ thống dùng 10 thủ tục công ty, 49 fragments và Qwen3-1.7B local. Kết quả cho thấy pipeline Docker hoạt động xuyên suốt; output và citation tuân thủ contract mà không gửi dữ liệu công ty tới Hosted API. Retrieval và quyết định trạng thái vẫn cần cải thiện. Vì vậy, đây là nền tảng demo nội bộ hoàn chỉnh về luồng kỹ thuật, chưa phải sản phẩm sẵn sàng triển khai thực tế.

7 Video Demo

Video demo hệ thống LLM tư vấn pháp lý cơ bản